

# Construção do Dataset Semântico de Pessoas Jurídicas

**Tulio Vidal Rolim<sup>1,2</sup>, Caio Viktor Silva Avila<sup>1</sup>, Renato Freitas<sup>1</sup>,  
Roberval Gomes Mariano<sup>1</sup>, Vania Maria Ponte Vidal<sup>1</sup>**

<sup>1</sup>Department of Computing – Federal University of Ceará (UFC)  
Fortaleza – CE – Brazil

<sup>2</sup>Instituto Federal de Educação, Ciência e Tecnologia do Piauí (IFPI)

{tulio.xcrtf, arlaass, jrenatosfreitas, mariano.rgml, vania.pvidal}@gmail.com

**Abstract.** *The Federal Revenue of Brazil provides registration data on companies, establishments and corporate bodies through the National Register of Legal Entities (CNPJ), serving as a reliable and accessible source of data. However, obtaining and managing this data is not a trivial task. This work carries out the first initiative to build a semantic dataset (DS) of Legal Entities based on a Data Lakehouses and semantics architecture. Throughout this article, the dataset construction process is described, also providing the resources, scripts and artifacts used, as well as an exploration through GraphDB and presentation of possible use cases.*

**Resumo.** *A Receita Federal do Brasil disponibiliza dados cadastrais de empresas, estabelecimentos e quadros societários através do Cadastro Nacional de Pessoas Jurídicas (CNPJ), servindo como uma fonte de dados confiável e acessível. Entretanto, obter e gerenciar esses dados não é uma tarefa trivial. Esse trabalho realiza a primeira iniciativa para construção de um dataset semântico (DS) de Pessoas Jurídicas baseado em uma arquitetura de Data Lakehouses e semântica. No decorrer deste artigo é descrito processo de construção do dataset, fornecendo também os recursos, scripts e artefatos utilizados, além de uma exploração através do GraphDB e apresentação de possíveis casos de uso.*

## 1. Introdução

Nos últimos anos, com o aumento da quantidade de dados públicos disponíveis, também houve um aumento na necessidade de integrar dados advindos de fontes distintas e com formatos heterogêneos.

Considerando dados públicos, os dados de pessoas jurídicas são uma importante fonte para questões fiscais, sendo essenciais para diagnosticar eventuais irregularidades, auxiliando na descoberta de ações não saudáveis por parte de empresas no âmbito público. Trabalhos como os de [de Oliveira Araújo et al. 2015], [Nascimento 2017] demonstram esforços para gerenciar e representar a crescente quantidade de coleções de dados públicos através de uma semântica bem definida na melhoria do processo de descoberta de conhecimento.

O Cadastro Nacional de Pessoas Jurídicas (CNPJ) da Receita Federal do Brasil (RFB) disponibiliza dados cadastrais de empresas, estabelecimentos e quadros societários, servindo como uma fonte de dados confiável e acessível. Entretanto, obter e gerenciar esses dados não é uma tarefa trivial.