

Nesse sentido, o *Data Lakehouse* emerge como uma arquitetura de dados inovadora, combinando as vantagens dos *data lakes* e *data warehouses* para fornecer uma camada de armazenamento unificada, eficiente e gerenciável. Um dos principais benefícios do *Data Lakehouse* é o suporte a transações ACID (Atomicidade, Consistência, Isolamento e Durabilidade), que assegura operações de leitura e escrita confiáveis e consistentes, mesmo em ambientes de alta concorrência [Cherradi 2024].

O conceito de *Data Lakehouse* foi introduzido para abordar as limitações dos *Data Lakes* e *Data Warehouses*, já que o primeiro, embora sejam altamente escaláveis e capazes de armazenar dados em qualquer formato, muitas vezes sofrem com a falta de governança e qualidade de dados. Por outro lado, os *Data Warehouses* fornecem uma estrutura mais rígida e eficiente para consultas, porém não conseguem lidar com a variedade e volume de dados [Armbrust et al. 2021].

Além disso, utilizar esses dados em conjunto com tecnologias semânticas e grafos de conhecimento facilita o tratamento de grandes conjuntos de dados, proporcionando uma visão unificada e permitindo integrações com outras fontes e *datasets*. Em conjunto, tecnologias semânticas possibilitam a criação de conhecimento explícito a partir de dados implícitos, possibilitando o uso de *reasoners*, que inferem novos fatos com base em regras predefinidas, sendo possível derivar novas relações e *insights* [Ehrlinger and Wöß 2016].

Esse trabalho realiza a primeira iniciativa para construção de um *dataset* semântico (*DS*) de Pessoas Jurídicas baseado em uma arquitetura de *Data Lakehouses* <https://github.com/semantic-ekgraphs/dataset-semantic-pj>.

As principais contribuições deste artigo são: *i)* Proposta de Arquitetura baseada em um *Data Lakehouse* e semântica para geração de um *dataset*; *ii)* Uma metodologia para a aquisição e o armazenamento de dados do Cadastro Nacional de Pessoa Jurídica (CNPJ); *iii)* *Dataset* semântico do CNPJ;

2. Descrição da Fonte de Dados Aberta (RFB)

A Receita Federal do Brasil (RFB), ou Secretaria Especial da Receita Federal do Brasil, é um órgão que tem como responsabilidade a administração dos tributos federais e o controle aduaneiro, além de atuar no combate à evasão fiscal (sonegação), contrabando, descaminho, contrafação (pirataria) e tráfico de drogas, armas e animais.

A RFB é fonte de dados primária responsável por fornecer a informação fidedigna de CPFs e CNPJs. Logo, uma empresa que não tem CNPJ cadastrado na RFB é, então, uma empresa de fato, mas não de direito, já que estará fazendo exercício ilegal das suas atividades. Os dados do Cadastro Nacional de Pessoa Jurídica da RFB, fonte de dados alvo deste trabalho, são disponibilizados no link¹ e o Layout oficial dos dados no link².

Além das informações de pessoa jurídica (empresa e estabelecimento), também são fornecidos dados sobre o quadro societário e de tabelas complementares, como: Tabela de Qualificações, Naturezas Legais, Simples Nacional/MEI³ e Razão de Situação Cadastral⁴.

¹<https://tinyurl.com/44z6xkk9>

²<https://www.gov.br/receitafederal/dados/cnpj-metadados.pdf>

³<http://200.152.38.155/CNPJ/Simples.zip>

⁴<http://200.152.38.155/CNPJ/Motivos.zip>