

3. Metodologia para Construção do *Dataset Semântico*

O uso de *Delta Lake* apresenta-se como uma solução robusta para muitos dos desafios enfrentados pelos *Data Lakes* tradicionais [Armbrust et al. 2020]. Nesse sentido, *Delta Lake* é uma *framework* de armazenamento que permite a criação de *Delta Tables*, proporcionando Transações ACID, *Data History*, *Change Data Feed*, Otimização Automática, *Schema Evolution* e Gerenciamento de Dados Não Estruturados [Haelen and Davis 2023]. Essa solução trata o fluxo dos dados e organiza-o na arquitetura *Medallion*, também conhecida como arquitetura de camadas, um *design* adotado pelo *Delta Lake* para organizar dados de forma hierárquica e incremental, visando melhorar a qualidade dos dados e a eficiência das consultas, sendo essa uma abordagem amplamente utilizada em arquiteturas de *Data Lakehouse* [Databricks 2021].

A arquitetura geral adotada para construção do *dataset* do Cadastro Nacional de Pessoas Jurídicas com base em um *Data Lakehouse Semântico* é apresentada na Figura 1. Essa arquitetura serve para nortear a metodologia para desenvolvimento do *dataset* deste trabalho. Na arquitetura apresentada, o *Data Lakehouse* é estruturado através do uso do *Delta Lake*. Ainda, a arquitetura utilizada como base é flexível e segue esquemas semanticamente coerentes, isto é, possibilitando que desenvolvedores, ainda não familiarizados com tecnologias semânticas, possam alternativamente realizar consultas em *SQL* ou desenvolver aplicações com os dados do CNPJ diretamente através das tabelas delta.




Figura 1. Arquitetura base para Geração do *Dataset*.

Para construção do *dataset*, a metodologia proposta é organizada da seguinte forma conforme (Figura 2): i) Aquisição dos dados; ii) Geração das Tabelas Bronze; iii) Geração das Tabelas Silver; iv) Geração das Tabelas Gold; v) Geração do *Dataset*.




Figura 2. Metodologia para Construção do *Dataset Semântico*.