

3.1. Etapa 1: Aquisição dos dados

A primeira etapa do *script Python*⁵ consiste no *download* de arquivos *.zip*. Em seguida, o conteúdo de cada arquivo é extraído no diretório *data/<concept>*, onde *<concept>* corresponde ao nome do conceito relacionado ao arquivo, *e.g Pais.zip* é extraído em *data/paises/*. Durante o processo, os arquivos são renomeados com a extensão *.csv*, pois, originalmente, eles são disponibilizados com o texto "CSV" ao final do nome, sem a extensão adequada. Exemplo: **F.K03200\$Z.D40608.PAISC**SV é renomeado para **F.K03200\$Z.D40608.PAIS**.CSV.

Durante o download dos dados, todo o processo tem seu log salvo em um arquivo *json* (**download_data.json**) contendo informações como: [**data de download dos arquivos, nome, tamanho em bytes**]. O *script* de aquisição dos dados também lida com a manutenção de versões anteriores, logo quando há verificação de que os dados disponibilizados no repositório ultrapassam a data de 30 dias, os dados atuais são movidos para um novo diretório chamado **data.old/** e os novos dados são salvos em **data/**.

3.2. Etapa 2: Geração das Tabelas Bronze

Esta etapa é iniciada com a ingestão dos dados. Durante o processo de ingestão, há uma classificação dos dados por conceitos existentes na ontologia, como Estabelecimentos, Sócios e Empresas. Essa classificação facilita o processo de carga das tabelas de extração.

Para tanto, o *script*⁶ de construção dessas tabelas segue o esquema de cada arquivo *.CSV* do CNPJ, garantindo conformidade com os dados disponibilizados originalmente, focando na carga direta, economizando tempo na ingestão dos dados. A Figura 3 apresenta uma análise exploratória das tabelas bronze geradas.




Figura 3. Distribuição de registros por tabela.

3.3. Etapa 3: Geração das Tabelas Silver

Nesta etapa, as tabelas bronze são tratadas por meio de diversas transformações e enriquecimentos para normalizar e facilitar o uso dos dados do CNPJ, como:

1. Criação de identificadores homogêneos, *e.g*: o identificador de CNPJ de cada estabelecimento é composto por 3 campos (**CNPJ_BASICO**, **CNPJ_ORDEM**, **CNPJ_DIV**) sendo necessário sempre realizar a concatenação para consultas que envolvam estabelecimento. Dessa forma foi gerado um campo único: **CNPJ**;

⁵<https://tinyurl.com/ye26w3my>

⁶<https://tinyurl.com/s3hp8vwh>