

Fazenda no estado. Isso inclui a identificação de empresas registradas no regime Simples Nacional ou como Microempreendedores Individuais (MEI) que estejam desempenhando atividades econômicas permitidas pela classificação CNAE. Essa verificação é essencial para garantir a conformidade com as políticas fiscais e prevenir a evasão de impostos.

Deteção de Inconsistências Cadastrais: O *DS* permite identificar empresas que compartilham as mesmas informações de contato, o que pode indicar a existência de fraudes ou irregularidades. Além disso, facilita a deteção de empresas sem sócios ativos ou com sócios falecidos, garantindo que apenas entidades em conformidade com as normas legais estejam operando.

Monitoramento de Atividades Econômicas: Com um dataset semântico, é possível monitorar empresas envolvidas em atividades econômicas incompatíveis. Esse monitoramento assegura que as empresas estejam operando em conformidade com as regulamentações vigentes e não apresentem riscos à segurança pública.

Validação de Endereços: Estabelecimentos sem endereços válidos podem ser detectados com facilidade, garantindo que todas as empresas possuam uma localização física verificável. Esta validação é crucial para a logística, inspeção e fiscalização de atividades comerciais.

Análise de Capital Social e Tamanho da Empresa: Através da análise semântica, a Secretaria da Fazenda pode identificar empresas cujo capital declarado é inconsistente com o porte ou a atividade econômica desempenhada. Essa análise ajuda a identificar possíveis fraudes financeiras ou irregularidades contábeis.

7. Desafios e Limitações

A construção de um dataset para os dados do CNPJ possui um conjunto de desafios como:

i) Armazenamento de um grande volume de dados: Os dados do CNPJ totalizam mais de 30GB somente em formato *.zip* e mais de 60 Milhões de registros apenas considerando empresas e estabelecimento, logo demandando de espaço para armazenamento e exigindo um considerável custo para tratamento bem como no processamento de consultas; **ii) tratamento dos dados limpeza e normalização:** os dados do CNPJ são agrupados em arquivos *.CSV*, onde alguns desses contemplam um grande conjunto de informações, como por exemplo, os arquivos de Estabelecimento que acoplam mais de 20 atributos por arquivo, dificultando um baixo acoplamento e dependência entre si desses dados, bem como à resolução de identidade de novas entidades, tal como os dados de endereço.

iii) Identidade Fraca: Alguns dos conceitos possuem identidade fraca, demandando da combinação de atributos (atributos compostos), gerando uma maior complexidade para se realizar junções e consequentemente dificultando a formulação e realização de consultas. *E.g* um estabelecimento é definido por três campos (**CNPJ_BASIC**, **CNPJ_ORDEM** e **CNPJ_DIV**), conforme citado anteriormente na subseção 3.3

iv) Compreensão do domínio: Alguns termos e conceitos do domínio não são explícitos a partir do layout de dados. Onde, para identificar a relação de um sócio com uma empresa, *i.e* a definição de um quadro societário, por exemplo, faz-se necessário identificar não só o *cnpj* da empresa e *cpf* do sócio, mas também seu nome, tendo em vista que o *cpf* é anonimizado e fornece apenas os 6 dígitos centrais principais, sendo em alguns casos, oportuno utilizar a qualificação do sócio.