

8. Trabalhos Relacionados

Trabalhos recentes demonstram esforços para se integrar a crescente quantidade de coleções de dados públicos. [Barbosa 2023] aborda a implementação de um *dataset* semântico utilizando um *Datalake* municipal para o Rio de Janeiro, destacando sua relevância no setor público, principalmente em termos de escalabilidade, governança e políticas públicas, sendo potencialmente replicável em outras cidades e países.

[Braz et al. 2023] apresenta um estudo que gerou um *dataset* de empresas relacionadas a licitações públicas no estado de Minas Gerais envolvidas em fraudes ou com comportamentos suspeitos, sendo um *dataset* útil para aprimorar os mecanismos de prevenção e controle de fraudes nos processos licitatórios.

Por sua vez, [do Prado Pagotto et al. 2024] propõem a criação de um *data lake* para armazenar e sistematizar dados de saúde no Brasil. O *dataset* gerado é composto por informações de diferentes fontes do sistema de saúde, incluindo dados sobre pacientes, atendimentos médicos, hospitais e indicadores de saúde pública, tendo como finalidade apoiar decisões informadas e desenvolver políticas públicas mais precisas na área de saúde.

Tendo em vista os trabalhos anteriormente citados, podemos observar que os estudos e pesquisas na área concentram-se na integração de dados governamentais e geração de *datasets* para domínios como (educação, saúde, políticas públicas). Já o trabalho atual propõe a criação de um *dataset* semântico de Pessoas Jurídicas, baseado no Cadastro Nacional de Pessoas Jurídicas, diferenciando-se por tratar todo o processo para a criação de um *dataset* semântico baseado em dados abertos públicos, desde sua modelagem, representação, geração e consumo.

Esse trabalho também adota uma arquitetura híbrida baseada em um *Data Lakehouse*, que combina aspectos de data lakes e data warehouses incorporando uma camada semântica para enriquecer o *dataset*. Esse tipo de arquitetura para geração do *dataset* não foi abordada nos trabalhos anteriores, tratando apenas de data lakes tradicionais. Ainda, este trabalho gera diversas contribuições ao conjunto de dados original, realizando limpeza, tratamento e normalização aos dados, agrupando conceitos previamente complexos bem como gerando novos, tal como citado na subseção 3.3.

9. Considerações Finais

Este artigo apresentou uma metodologia para construção de um *dataset* semântico *DS* do Cadastro Nacional de Pessoas Jurídicas (CNPJ), apresentando uma arquitetura baseada em *Data Lakehouses* enriquecida de semântica, fornecendo uma base teórica e prática para a aquisição, tratamento, normalização, limpeza dos dados e geração do *dataset*.

Todas as etapas da metodologia foram detalhadas, apresentando os recursos e *scripts* necessários, apresentando também contribuições realizadas aos dados. Por conseguinte, o *DS* gerado é apresentado através do *GraphDB*, onde é apresentada uma consulta exploratória demonstrando a visualização dos dados, propriedades e relações de um recurso Estabelecimento.

Ao final, este trabalho sugere além do *dataset* semântico gerado, uma perspectiva na adoção de novas tecnologias como *Data Lakehouse* em conjunto com semântica para geração de *datasets* de dados públicos, apresentando uma metodologia e detalhes de todas