

as suas etapas, possibilitando que outros estudos o utilizem para geração de novos *datasets* públicos nos mais variados domínios e contextos.

Como trabalhos futuros pretende-se enriquecer o *DS* do CNPJ realizando integrações com outros *datasets* relevantes como Cadastro Nacional de Atividades Econômicas (CNAE) do IBGE, o Cadastro de Imóveis e Suspensos (CEIS), TCU e Portal de Compras Governamentais.

Referências

- Armbrust, M., Das, T., Sun, L., Yavuz, B., Zhu, S., Murthy, M., Torres, J., van Hovell, H., Ionescu, A., Łuszczak, A., et al. (2020). Delta lake: high-performance acid table storage over cloud object stores. *Proceedings of the VLDB*, 13(12):3411–3424.
- Armbrust, M., Ghodsi, A., Xin, R., and Zaharia, M. (2021). Lakehouse: a new generation of open platforms that unify data warehousing and advanced analytics. In *Proceedings of CIDR*, volume 8, page 28.
- Barbosa, R. P. C. (2023). Potencializando o uso de dados em políticas públicas através do primeiro datalake municipal no mundo no rio de janeiro. *Enepcp*.
- Bertails, A. and Prud’hommeaux, E. G. (2011). Interpreting relational databases in the rdf domain. In *Proceedings of the sixth international conference on Knowledge capture*, pages 129–136.
- Braz, C. S., Mendes, B. M., Oliveira, G. P., Costa, L. L., Silva, M. O., Brandao, M. A., Lacerda, A., and Pappa, G. L. (2023). Análise de irregularidades em licitações públicas com foco em empresas de pequeno porte. In *Anais do XI Workshop de Computação Aplicada em Governo Eletrônico*, pages 94–105. SBC.
- Cherradi, M. (2024). Data lakehouse: Next generation information system. In *Seminars in Medical Writing and Education*, volume 3, pages 67–67.
- Databricks (2021). What is a medallion architecture. <<https://www.databricks.com/glossary/medallion-architecture>>. Acessado em: 15-07-2024.
- de Oliveira Araújo, L. S., Santos, M. T., and Silva, D. A. (2015). The brazilian federal budget ontology: a semantic web case of public open data. In *Proceedings of the 7th International Conference on Management of computational and collective intelligence in Digital EcoSystems*, pages 85–89.
- do Prado Pagotto, D., da Silva Marques, W., de Oliveira, D. S., Ferreira, V. d. R. S., de Azevedo, V. N., and Júnior, C. V. B. (2024). Inovação em saúde: a implementação de um data lake para armazenamento, sistematização e disponibilização de dados em saúde no brasil. *InCID: Revista de Ciência da Informação e Documentação*, 15(1).
- Ehrlinger, L. and Wöß, W. (2016). Towards a definition of knowledge graphs. *SEMAN-TiCS (Posters, Demos, SuCCESS)*, 48(1-4):2.
- Haelen, B. and Davis, D. (2023). *Delta Lake: Up and Running*. ”O’Reilly Media, Inc.”.
- Nascimento, L. M. (2017). Utilizando linked data para publicação e cruzamento de dados governamentais abertos. Master’s thesis, Universidade Federal Fluminense.
- W3C (2012a). A direct mapping of relational data to rdf.
- W3C (2012b). R2rml: Rdb to rdf mapping language.